DAFTAR REVISI TERSTRUKTUR II

Hasil Pemeriksaan Menyeluruh Tiga Notebook Eksperimen

Penelitian Dekoding Metafora Sampul Majalah Tempo

Keterangan	Isi
Ditujukan kepada	Joy Eau Dia, Mahasiswa Peneliti Utama
Dari	Feliks V. P. Samosir, S.Pd., M.Kom, Dosen Pembimbing
Berkas yang diperiksa	01_baseline.ipynb, 02_experiments.ipynb, 03_final_comparison.ipynb (rilis 20 dan 27 Oktober 2026)
Tanggal terbit	27 Oktober 2026
Sisa linimasa	sekitar 9 pekan sampai akhir Desember 2026
Keputusan lingkup	Model utama yang dilaporkan adalah CLIP + IndoBERT dengan MTL Joint Loss. Qwen3-VL-8B + QLoRA berstatus pembanding saja.
Jumlah butir revisi	19 butir baru (R18 sampai R36), ditambah 7 butir Agustus yang belum tuntas

Catatan Pengantar

Saya membongkar ketiga notebook, membaca seluruh sel beserta keluaran tersimpannya, lalu merekonstruksi ulang setiap angka utama dari tabel metrik per kelas. Rekonstruksi saya cocok persis sampai empat desimal pada ketiga task. Angka yang kamu laporkan nyata dan dapat ditelusuri. Pemeriksaan ini bukan tentang kejujuran data, melainkan tentang metrik, kontrol, dan tafsir.

Hal yang memang kuat

Perlu dinyatakan lebih dahulu supaya daftar panjang di bawah dibaca dengan proporsi yang benar.

1. Nested cross-validation lima fold dengan pemisahan inner dan outer yang benar, protokol dibekukan, dan SHA256 atas dataset, source, split, prediksi, serta audit input. Fungsi verify_fold penuh assert yang memeriksa ulang argmax probabilitas, kesetaraan micro dengan akurasi, dan kecocokan seluruh hash. Tingkat kerapian ini lebih tinggi daripada kebanyakan artikel yang terbit.
2. Pelaporan hasil negatif dilakukan terbuka. E12 dinyatakan gagal dan tidak dipromosikan menjadi kandidat terbaik. Nilai yang tidak terukur ditulis "Not Evaluated" dan tidak diisi angka karangan.
3. Kolom comparison_scope secara eksplisit memperingatkan kapan dua baris tidak sebanding, misalnya "protocol_changed_full_nesting; not an isolated ablation". Kebiasaan ini jarang ditemukan bahkan pada peneliti senior.
4. Ada pernyataan terbuka bahwa seluruh evaluasi adalah internal repeated-corpus CV dan bukan independent acceptance data.

Disiplin rekayasa ini aset nyata, dan tidak satu pun butir di bawah membatalkannya. Masalahnya berada di lapisan pemilihan metrik dan penafsiran.

Temuan tunggal yang paling menentukan

Satu temuan menaungi hampir seluruh dokumen ini. Seluruh jalur keputusan eksperimen, dari E01 sampai E14, digerakkan oleh Micro-F1. Pada klasifikasi multikelas label tunggal, Micro-F1 identik dengan akurasi, dan kodemu sendiri membuktikannya lewat assert berikut.

```
assert abs(score - accuracy_score(truth, predictions[task+"_pred"])) < 1e-12
```

Saya hitung korelasi peringkat Spearman antara peringkat berdasarkan Micro-F1 minimum dan peringkat berdasarkan Macro-F1 minimum, atas 36 kandidat non-VLM dalam lampiranmu. Hasilnya +0.050.

Korelasi peringkat sebesar itu praktis nol. Artinya, seleksi model yang kamu lakukan selama berbulan-bulan hampir tidak membawa informasi apa pun tentang peringkat macro. Konsekuensi konkretnya ada di tabel berikut.

Kandidat	Peringkat micro	Peringkat macro	Pergeseran
MICRO_E11_hierarchical_task3	#1	#32	turun 31 peringkat
MICRO_E12_structured_decoder	#2	#30	turun 28 peringkat
M00_e42_baseline	#23	#1	naik 22 peringkat
e42_tail_grid	#24	#2	naik 22 peringkat
e44_focal_tail	#25	#3	naik 22 peringkat

E11, kandidat terbaik menurut seleksimu, berada di peringkat 32 dari 36 menurut macro-F1. Sebaliknya, e42_tail_grid dan M00_e42_baseline yang kamu tinggalkan justru terbaik menurut macro-F1. Kalau macro-F1 dijadikan metrik utama sebagaimana ditetapkan pada butir R12 bulan Agustus, arah riset selama ini keliru sejak awal.

Perlu kamu baca dengan tenang. Temuan ini tidak membatalkan pekerjaanmu. Pembalikan peringkat sebesar ini justru temuan metodologis yang layak menjadi salah satu sumbangan utama naskah, asalkan dilaporkan secara terbuka dan bukan disembunyikan.

Batas pemeriksaan ini

Arsip yang kamu kirim hanya berisi tiga berkas .ipynb. Seluruh path yang dirujuk sel pertama, yaitu tools/analysis.py, project/DEMO_XAI_745_FULL, dan predictions.csv, tidak disertakan. Notebook akan gagal pada sel pertama dengan FileNotFoundError kalau dijalankan orang lain. Analisis saya bersandar sepenuhnya pada keluaran yang tersimpan di dalam notebook. Beberapa butir di bawah berbentuk permintaan verifikasi, bukan tuduhan, justru karena berkas pendukungnya tidak dapat saya periksa.

Cara membaca prioritas

P1, Blokir. Harus selesai dalam dua pekan, paling lambat 9 November. Selama P1 belum tuntas, jangan menjalankan eksperimen baru dan jangan mulai menulis bab hasil, karena identitas model utama dan kesahihan angkanya belum pasti.

P2, Eksperimen wajib. Pekerjaan komputasi yang harus ada sebelum naskah dapat mengklaim apa pun. Dikerjakan 10 sampai 23 November.

P3, Perumusan di manuskrip. Tidak menambah eksperimen, tetapi menentukan apakah naskah diterima atau ditolak pada putaran pertama.

Bagian 0. Status Butir Revisi Agustus

Daftar revisi 17 Agustus memuat 17 butir. Berikut status yang dapat saya nilai dari ketiga notebook. Butir yang belum tuntas tidak dinomori ulang, dan tetap berlaku.

No	Butir Agustus	Status	Catatan dari notebook
R2	Definisi operasional tiga task head	Sebagian	Task sudah terdefinisi jelas, tetapi kelas penampung tidak terdefinisi dan menjadi kelas terburuk pada ketiga task
R4	Spike kelayakan GRAD-CAM pada CLIP	Belum terlihat	Tidak ada jejak GRAD-CAM di notebook mana pun
R6	Adjudikasi menggantikan penghapusan sampel	Tidak terverifikasi	Dataset turun dari 1.040 menjadi 740 tanpa penjelasan
R8	Lima konfigurasi baseline dan ablasi	Sebagian	Ablasi ada, tetapi prediksi mentah unimodal tidak disimpan sehingga uji berpasangan mustahil
R9	Penilai kualitas XAI independen	Belum	Nol kemunculan kata rubrik, penilai, Likert, faithfulness
R12	Macro-F1 sebagai metrik utama	TIDAK dijalankan	Macro disimpan dengan nama variabel macro_f1_diagnostic. Gate memakai micro
R13	Justifikasi ulang target F1	Belum	Gate 0.70 masih dipakai tanpa dasar baru
R16	Pelengkapan sitasi	Belum terlihat	Di luar cakupan notebook
R17	Bagian etika dan penyalahgunaan	Belum terlihat	Di luar cakupan notebook

Butir R12 adalah akar sebagian besar persoalan dalam dokumen ini. Kalau butir itu dijalankan pada Agustus, pembalikan peringkat 31 posisi pada E11 akan terdeteksi dua bulan lebih awal, dan arah eksperimen September sampai Oktober akan berbeda. Saya mencatat ini bukan untuk menyalahkan, melainkan supaya kamu melihat biaya nyata dari melewati satu butir revisi tanpa penjelasan.

Bagian A. Revisi Prioritas P1 (Blokir)

R18. Tetapkan dan Bekukan Identitas Model Utama CLIP-IndoBERT

Prioritas: P1, Blokir **Tenggat:** 31 Oktober 2026

Temuan. Lampiran notebook 03 memuat 36 kandidat non-VLM dari keluarga CLIP, SigLIP2, dan DINOv2 yang dipadukan dengan IndoBERT. Tidak ada satu pun pernyataan mana di antaranya yang merupakan "arsitektur Multi-Task Learning CLIP-IndoBERT dengan Joint Loss" sebagaimana dijanjikan proposal. Nama BASELINE_CLIP_INDoBERT, M01_clip_indobert, e36_clip_l14, e42_tail_grid, dan MICRO_E11_hierarchical_task3 semuanya kandidat berbeda dengan angka yang sangat berbeda.

Mengapa ini penting. Angka headline naskahmu berubah total tergantung kandidat mana yang dipilih, dan rentangnya sangat lebar.

Kandidat	Macro T1	Macro T2	Macro T3	Min macro
BASELINE_CLIP_INDoBERT	0.4380	0.3197	0.2764	0.2764
MICRO_E11_hierarchical_task3	0.5103	0.5025	0.2825	0.2825
MICRO_E12_structured_decoder	0.5167	0.4935	0.2872	0.2872
M00_e42_baseline / e42_tail_grid	belum dibuka	belum dibuka	belum dibuka	0.3956
M01_clip_indobert	belum dibuka	belum dibuka	belum dibuka	0.3581

Selisih antara kandidat terburuk dan terbaik pada min macro-F1 adalah 11,9 poin persentase. Memilih kandidat setelah melihat angkanya, lalu menyebutnya "arsitektur yang diusulkan", adalah bentuk seleksi post-hoc yang akan ditanyakan penguji. Kamu tidak bisa lagi menghindari seleksi post-hoc karena seluruh eksperimen sudah berjalan, tetapi kamu wajib menyatakannya terbuka.

Tindakan yang harus dilakukan.

1. Buat tabel pemetaan lengkap. Satu baris per nama eksperimen, dengan kolom: backbone visual beserta variannya (CLIP ViT-B/32, ViT-L/14, SigLIP2, DINOv2), backbone tekstual, status fitur (beku atau fine-tuned), arsitektur head, apakah shared layer dipakai, fungsi loss, apakah uncertainty weighting aktif, dan skema augmentasi.
2. Tandai secara eksplisit kandidat mana yang memenuhi spesifikasi proposal, yaitu CLIP sebagai cabang visual, IndoBERT sebagai cabang tekstual, satu shared MTL layer, tiga head, dan satu Joint Loss. Kandidat yang memakai SigLIP2 atau DINOv2 bukan arsitektur yang dijanjikan proposal dan berperan sebagai ablasi backbone, bukan sebagai model utama.
3. Pilih satu model utama berdasarkan macro-F1 sesuai butir R19, bukan berdasarkan micro-F1.
4. Tulis satu paragraf yang menyatakan terus terang bahwa pemilihan dilakukan setelah seluruh kandidat dievaluasi pada korpus yang sama, beserta konsekuensinya terhadap klaim generalisasi. Kejujuran ini menutup serangan penguji jauh lebih efektif daripada menyembunyikannya.
5. Sisa kandidat tidak dibuang. Kelompokkan menjadi ablasi backbone (R29), ablasi augmentasi (R30), dan ablasi MTL (R27).

Bukti yang diserahkan. Tabel pemetaan 36 baris dalam format .csv atau .xlsx, dan satu paragraf penetapan model utama beserta alasannya.

R19. Peringkat Ulang Seluruh Kandidat Memakai Macro-F1

Prioritas: P1, Blokir. Butir paling menentukan dalam dokumen ini **Tenggat:** 3 November 2026

Temuan. Seluruh seleksi model sepanjang penelitian memakai Micro-F1 minimum lintas task. Saya hitung ulang peringkat 36 kandidat non-VLM menurut Macro-F1 minimum. Korelasi Pearson antara kedua metrik adalah +0.395, dan korelasi peringkat Spearman hanya +0.050.

Mengapa ini penting. Bagian ini perlu kamu baca dua kali, karena inilah inti seluruh dokumen.

1. Micro-F1 pada klasifikasi label tunggal identik dengan akurasi. Akurasi pada data timpang dapat naik hanya dengan memindahkan prediksi ke kelas mayoritas, tanpa model benar-benar belajar apa pun tentang kelas minoritas. Seluruh tabel "Micro-F1" dalam notebookmu sesungguhnya tabel akurasi dengan nama yang terdengar lebih teknis.
2. Gate kelulusanmu dihitung dari micro, dan macro disimpan dengan nama variabel macro_f1_diagnostic pada results.py. Macro-F1 secara harfiah diturunkan statusnya menjadi diagnostik. Butir R12 Agustus menetapkan sebaliknya.
3. Korelasi peringkat +0.050 berarti seleksi berbasis micro hampir tidak membawa informasi tentang peringkat macro. Bukan sekadar kurang optimal, melainkan nyaris tidak berkorelasi sama sekali. Sepuluh besar menurut kedua metrik hampir tidak beririsan.
4. Akibat praktisnya, kandidat yang kamu promosikan sebagai terbaik justru hampir terburuk menurut metrik yang benar, dan kandidat yang kamu tinggalkan justru terbaik. Kalau ini tidak diperbaiki, naskahmu akan melaporkan model yang salah sebagai hasil utama penelitian.

Tindakan yang harus dilakukan.

1. Hitung ulang macro-F1, macro-precision, macro-recall, dan Cohen kappa per task untuk seluruh 36 kandidat non-VLM dari berkas prediksi yang sudah tersimpan. Seluruhnya inferensi ulang metrik, tanpa pelatihan apa pun, dan dapat selesai dalam hitungan menit.
2. Susun tabel 36 baris dengan kolom: nama, macro-F1 per task, min macro, akurasi per task, min micro, peringkat micro, peringkat macro, dan pergeseran peringkat.
3. Berhenti memakai "minimum lintas task" sebagai kriteria tunggal. Minimum pada model yang berbeda bisa jatuh pada task yang berbeda, sehingga peringkatnya tidak koheren. Laporkan per task, dan kalau perlu satu angka ringkas, pakai rata-rata macro-F1 ketiga task dan nyatakan pilihan itu.
4. Laporkan pembalikan peringkat ini sebagai temuan metodologis tersendiri di bagian pembahasan. Judul kerjanya kira-kira "pemilihan metrik menentukan arah seleksi arsitektur pada data timpang". Temuan seperti ini punya nilai ilmiah lebih tinggi daripada sekadar melaporkan satu model menang.
5. Periksa apakah kesimpulan "E12 adalah hasil negatif" masih berlaku di bawah macro. Dari angka yang ada, E12 macro 0.5167/0.4935/0.2872 sebenarnya lebih baik daripada E11 pada task1 dan task3, dan hanya kalah pada task2. Kesimpulan E12 gagal berasal dari pembacaan micro.

Bukti yang diserahkan. Tabel peringkat ganda 36 baris, dan satu paragraf analisis pembalikan peringkat.

R20. Diagnosis Kolaps ke Kelas Mayoritas pada Task 3

Prioritas: P1, Blokir **Tenggat:** 3 November 2026

Temuan. Saya bandingkan BASELINE_CLIP_INDoBERT dengan MICRO_E11_hierarchical_task3 pada task3. Akurasi naik tajam sementara recall rata-rata kelas justru turun.

Model (task3)	Akurasi	Macro-F1	Prec macro	Recall macro
Majority baseline	0.4257	0.0746	n/a	n/a
BASELINE_CLIP_INDoBERT	0.3554	0.2764	0.2711	0.3176
MICRO_E12_CONTROL	0.5122	0.2716	0.3303	0.2674
MICRO_E12_structured_decoder	0.5108	0.2872	0.3215	0.2820
MICRO_E11_hierarchical_task3	0.5324	0.2825	0.3224	0.2793

Mengapa ini penting. Dari baseline ke E11, akurasi task3 naik 17,70 poin persentase, setara 131 sampul. Pada periode yang sama macro-F1 hanya naik 0,62 poin persentase, dan recall rata-rata kelas justru turun 3,83 poin persentase. Pola ini adalah tanda khas model yang memindahkan prediksinya ke kelas mayoritas. Kelas individual memegang 315 dari 740 sampul, atau 42,6 persen. Model menjadi lebih sering benar karena lebih sering menebak kelas besar, bukan karena lebih memahami kelas kecil. Lebih jauh, akurasi E11 sebesar 0.5324 hanya 10,68 poin persentase di atas majority baseline yang tidak belajar apa pun. Seluruh rangkaian optimasi task3 selama berbulan-bulan menghasilkan perbaikan nyata yang jauh lebih kecil daripada yang terlihat pada tabel micro.

Tambahan yang lebih keras. Model utama BASELINE_CLIP_INDoBERT mencatat akurasi task3 sebesar 0.3554, sementara majority baseline mencapai 0.4257. Arsitektur yang dijanjikan proposal kalah 7,03 poin persentase dari tebakan kelas terbanyak, setara 52 sampul. Uji McNemar memberi p antara 0,003 dan 1,5e-12 tergantung tingkat diskordansi, jadi selisih itu nyata dan bukan kebetulan. Fakta ini harus dilaporkan, bukan dihindari.

Tindakan yang harus dilakukan.

1. Bangun confusion matrix 8x8 untuk task3 pada model utama dan pada E11. Simpan sebagai gambar dan sebagai tabel angka.
2. Hitung distribusi prediksi per kelas dan bandingkan dengan distribusi gold. Tabel dua kolom, proporsi gold versus proporsi prediksi, per kelas. Kalau proporsi prediksi untuk kelas individual jauh melebihi 42,6 persen, kolaps terbukti secara kuantitatif.
3. Hitung entropi distribusi prediksi dan bandingkan dengan entropi distribusi gold. Angka tunggal ini ringkas dan mudah dimasukkan ke naskah.
4. Jalankan ulang model utama dengan class weighting pada fungsi loss, dengan bobot berbanding terbalik terhadap frekuensi kelas. Laporkan akurasi dan macro-F1 sebelum dan sesudah. Ekspektasi yang wajar adalah akurasi turun dan macro-F1 naik, dan pertukaran itulah yang justru perlu kamu tunjukkan.
5. Jangan terapkan oversampling atau class weighting pada data uji dalam keadaan apa pun. Hanya pada data latih.

Bukti yang diserahkan. Dua confusion matrix, tabel distribusi prediksi versus gold, angka entropi, dan tabel hasil sebelum dan sesudah class weighting.

R21. Kesetaraan Masukan antara Model Utama dan Pembanding

Prioritas: P1, Blokir **Tenggat:** 9 November 2026

Temuan. Setelah membaca worker.py, saya menemukan bahwa pembanding Qwen3-VL menerima masukan yang jauh lebih kaya daripada model utama. Prompt disusun begini.

```
"Judul: {row.headline_verified}. Teks pendukung: {row.supporting_text_verified}. "
"Deskripsi visual: {descriptions[index]['deskripsi'][:1000]}. "
"Observasi sumber visual: {(reasons[index].get('sumber_visual'))[:250]}. "
"Alasan visual: {(reasons[index].get('alasan'))[:500]}."
```

Pembanding menerima sampai 1.750 karakter fitur teks tambahan berupa deskripsi visual dan observasi terstruktur, sementara model utama CLIP-IndoBERT hanya menerima fitur citra CLIP dan judul lewat IndoBERT.

Mengapa ini penting. Selisih kinerja antara kedua model saat ini mencampur sedikitnya tiga sebab yang tidak dapat dipisahkan, yaitu ukuran model (8 miliar parameter versus head kecil di atas fitur beku), kekayaan pretraining, dan kekayaan masukan. Dalam posisi barumu, di mana CLIP-IndoBERT adalah model utama dan Qwen hanya pembanding, ketidaksetaraan ini merugikan model utamamu sendiri. Pembanding diberi keunggulan yang tidak diberikan kepada model yang kamu pertahankan, sehingga naskahmu akan terlihat seperti sengaja melemahkan arsitektur yang diusulkan. Penguji akan menanyakan hal ini dengan tajam, dan jawabannya harus berupa angka, bukan argumen.

Tindakan yang harus dilakukan. Jalankan tiga konfigurasi berikut.

1. Qwen3-VL zero-shot tanpa fine-tuning pada 740 OOF yang sama, dengan prompt identik. Konfigurasi ini memisahkan sumbangan QLoRA dari kemampuan bawaan model. Saat ini angka itu sama sekali tidak ada pada 740, hanya ada kontrol 119 sampel pada E13 dengan lebar CI sekitar 18 poin persentase dan tumpang tindih penuh dengan hasil fine-tune. Biayanya inferensi saja, tanpa pelatihan.
2. Qwen3-VL QLoRA tanpa fitur tambahan, yaitu hanya citra dan judul, supaya setara dengan masukan model utama. Konfigurasi ini memisahkan sumbangan fitur dari sumbangan ukuran model.
3. CLIP-IndoBERT dengan fitur teks tambahan yang sama, yaitu supporting_text_verified dan deskripsi visual dialirkan lewat IndoBERT. Konfigurasi ini menguji apakah model utamamu sebenarnya tertinggal karena masukannya miskin, bukan karena arsitekturnya lemah. Kalau hasilnya naik tajam, kamu punya temuan penting dan sekaligus pembelaan kuat untuk arsitektur yang diusulkan.
4. Sajikan keempat sel perbandingan dalam satu tabel dua dimensi, dengan baris arsitektur dan kolom kekayaan masukan. Tabel seperti ini langsung menjawab pertanyaan penguji sebelum ditanyakan.

Bukti yang diserahkan. Tabel 2x2 arsitektur versus masukan, dengan macro-F1 dan kappa per task beserta selang kepercayaan.

R22. Pembuktian Provenance deskripsi.jsonl dan zeroshot.jsonl

Prioritas: P1, Blokir. Berpotensi membatalkan seluruh hasil task2 **Tenggat:** 31 Oktober 2026

Temuan. Kedua berkas dibuat sekali untuk seluruh 740 sampel sebelum pembagian fold, lalu disuntikkan ke dalam prompt. Berkas zeroshot.jsonl memuat medan bernama sumber_visual, dan kata "sumber" persis adalah konsep target task2_domain_sumber.

Mengapa ini penting. Kalau kedua berkas itu dibuat oleh proses yang pernah melihat kolom label gold, maka task2 terkontaminasi pada seluruh lima fold sekaligus. Nested cross-validation yang kamu bangun dengan sangat rapi tidak menolong sedikit pun dalam kasus itu, karena kebocorannya terjadi di hulu, pada tahap pembuatan fitur, sebelum fold mana pun dibentuk. Hasil task2 akan harus dibatalkan seluruhnya. Prompt memang diawali kalimat "Analisis sampul majalah Tempo tanpa memakai label anotasi", dan saya menduga memang aman. Tetapi dugaan tidak cukup. Ini harus dapat dibuktikan kepada penguji dengan berkas, bukan dengan ingatan.

Tindakan yang harus dilakukan.

1. Serahkan skrip pembangkit kedua berkas, lengkap dan dapat dijalankan.
2. Serahkan prompt lengkap yang dipakai saat pembangkitan, nama dan revisi model pembangkit, serta stempel waktu pembuatan.
3. Tunjukkan secara eksplisit bahwa berkas dataset berlabel tidak pernah masuk ke dalam cakupan proses itu, misalnya dengan menunjukkan daftar berkas masukan skrip tersebut.
4. Serahkan SHA256 kedua berkas dan bandingkan dengan hash yang sudah tercatat di worker.py, yaitu c75e8df3... untuk deskripsi dan 10c07b06... untuk zeroshot.
5. Periksa manual 20 baris acak zeroshot.jsonl dan pastikan isinya berupa observasi visual bebas, bukan label kategori task2. Kalau medan sumber_visual ternyata berisi nama kelas seperti MESIN_INFRASTRUKTUR, kontaminasinya langsung terbukti dan harus segera dilaporkan kepada saya.

Bukti yang diserahkan. Skrip pembangkit, prompt, metadata model, daftar hash, dan 20 baris contoh.

R23. Kesepakatan Antaranotator dan Riwayat Penyusutan 1.040 ke 740

Prioritas: P1, Blokir. Angka paling penting yang hilang **Tenggat:** 9 November 2026

Temuan. Kata kappa, anotator, annotator, agreement, dan adjudikasi tidak muncul satu kali pun di ketiga notebook. Sementara itu dataset menyusut dari 1.040 sampel pada proposal menjadi 740 tanpa penjelasan di mana pun.

Mengapa ini penting. Ada dua persoalan terpisah, dan keduanya berat.

1. Tanpa angka kesepakatan antaranotator, penelitian ini tidak dapat menafsirkan hasilnya sendiri. Saya hitungkan Cohen kappa model terhadap gold dari tabel per kelas pembanding, yaitu 0.675 pada task1, 0.471 pada task2, dan 0.552 pada task3. Angka-angka itu tidak punya makna tanpa pembanding manusia. Kalau kappa antaranotator pada task2 ternyata sekitar 0.50, model sudah menyentuh langit-langit manusia dan target 0.70 memang tidak pernah bisa dicapai siapa pun. Kalau kappa antaranotator 0.75, berarti masih ada ruang nyata. Penguji pasti menanyakan apakah 0.5662 itu kegagalan model atau batas ketidakjelasan tugasnya, dan sekarang kamu belum punya jawabannya.

2. Penyusutan 300 sampel berpotensi fatal kalau berasal dari pembuangan sampel yang tidak disepakati anotator. Butir R6 Agustus sudah memperingatkan hal ini secara spesifik. Membuang kasus sengketa berarti model hanya diuji pada kasus mudah, dan seluruh akurasi yang dilaporkan menjadi optimistis secara sistematis. Lebih buruk lagi, penelitian yang mengklaim menangani satire berlapis justru membuang sampul yang paling berlapis.

Tindakan yang harus dilakukan.

1. Hitung Cohen kappa antaranotator per task dari berkas anotasi mentah kedua anotator. Kalau anotasi ganda memang dilakukan, angka ini sudah ada datanya dan hanya perlu dihitung.
2. Kalau anotasi ganda ternyata tidak pernah dilakukan pada seluruh korpus, lakukan anotasi ganda pada subsampel acak minimal 150 sampul sekarang juga, lalu hitung kappa dari subsampel itu. Pekerjaan ini kira-kira sepuluh jam untuk dua anotator dan harus dimulai pekan ini.
3. Sajikan tabel pembanding langsung, dengan baris per task dan kolom kappa antaranotator, kappa model utama, dan kappa pembanding. Tabel ini akan menjadi salah satu tabel terpenting dalam naskahmu.
4. Tulis riwayat lengkap penyusutan korpus. Berapa sampul awal, berapa yang gugur, dan atas kriteria apa. Kalau kriterianya ketidaksepakatan anotator, nyatakan terbuka dan hitung ulang hasil pada korpus penuh sebagai analisis sensitivitas.
5. Kalau sampul yang dibuang masih tersimpan, jalankan model utama pada sampul tersebut dan laporkan selisih kinerjanya. Selisih itu mengukur secara langsung seberapa optimistis angka utamamu.

Bukti yang diserahkan. Tabel kappa antaranotator per task, riwayat penyusutan korpus, dan analisis sensitivitas pada sampul yang dibuang.

Bagian B. Revisi Prioritas P2 (Eksperimen Wajib)

R24. Penggantian Metrik Utama dan Penghapusan Istilah Micro-F1

Prioritas: P2 **Tenggat:** 10 November 2026

Temuan. Seluruh pelaporan memakai Micro-F1 sebagai metrik utama, dengan gate all_tasks_at_least_0_70 yang dihitung hanya dari micro. Macro-F1 disimpan sebagai macro_f1_diagnostic.

Mengapa ini penting. Di bawah macro-F1, tidak ada satu pun task yang lulus, bahkan pada pembanding Qwen sekalipun. Selisih micro terhadap macro adalah 4,69 poin persentase pada task1, 5,59 pada task2, dan 7,21 pada task3. Selisih itu bukan noise, melainkan ukuran langsung dari seberapa besar akurasi ditopang kelas mayoritas. Menyebut akurasi sebagai Micro-F1 juga memberi kesan metrik yang lebih canggih daripada kenyataannya, dan reviewer yang mengenal bidang ini akan menganggapnya sebagai usaha memperhalus.

Tindakan yang harus dilakukan.

1. Tetapkan macro-F1 sebagai metrik utama di seluruh naskah dan seluruh tabel.
2. Tambahkan Cohen kappa sebagai metrik pendamping. Kappa sudah terkoreksi terhadap kebetulan dan langsung sebanding dengan kesepakatan antaranotator pada butir R23.
3. Ganti seluruh label kolom "Micro-F1" menjadi "Akurasi". Tulis apa adanya. Kalau tetap ingin menyebut micro-F1, sertakan catatan kaki bahwa pada klasifikasi label tunggal keduanya identik secara matematis.
4. Ganti nama variabel macro_f1_diagnostic menjadi macro_f1 pada results.py, dan pindahkan gate ke macro.
5. Sertakan tabel metrik per kelas untuk model utama pada ketiga task. Tabel per kelas biasanya menjadi bagian paling informatif dalam naskah semacam ini, dan justru di situlah kelemahan model terlihat jujur.
6. Laporkan macro-precision dan macro-recall terpisah, tidak hanya macro-F1. Pada kasus task3, justru pasangan precision dan recall yang menyingkap kolaps kelas mayoritas.

Bukti yang diserahkan. Seluruh tabel hasil dalam versi macro, dan berkas results.py yang sudah direvisi.

R25. Selang Kepercayaan dan Uji Signifikansi pada Setiap Klaim Selisih

Prioritas: P2 **Tenggat:** 16 November 2026

Temuan. Tidak ada satu pun selang kepercayaan di seluruh paket. Notebook 03 melaporkan kenaikan E11 ke E14 pada task2 sebesar 0.675676 poin persentase, ditulis sampai enam desimal. Angka itu setara 5 sampul dari 740.

Mengapa ini penting. Saya hitung batas uji McNemar untuk selisih tersebut pada semua tingkat diskordansi yang masuk akal, dan p berkisar 0,07 sampai 0,78. Selisih itu tidak signifikan dengan cara apa pun. Untuk mendeteksi selisih sekecil itu secara meyakinkan dibutuhkan antara 12.600 sampai 29.400 sampel. Melaporkannya sampai enam desimal memberi kesan presisi yang tidak dimiliki data.

Pada n sama dengan 740, selang kepercayaan Wilson untuk akurasi selebar sekitar plus minus 3,3 poin persentase, jadi banyak selisih yang kamu laporkan sebenarnya berada di dalam derau.

Tindakan yang harus dilakukan.

1. Lampirkan selang kepercayaan Wilson 95 persen pada setiap angka akurasi, dan selang kepercayaan bootstrap pada setiap angka macro-F1 dengan minimal 2.000 kali resampling.
2. Lakukan uji McNemar berpasangan untuk setiap klaim selisih antarmodel. Uji ini memerlukan prediksi mentah kedua model pada sampel yang sama, dan karena seluruh model dievaluasi pada 740 OOF yang sama, syarat itu terpenuhi asalkan prediksinya tersimpan.
3. Cabut klaim kenaikan task2 dari E11 ke E14. Ganti dengan pernyataan bahwa kedua model setara pada task2 dalam batas ketelitian data.
4. Bulatkan seluruh pelaporan ke dua desimal untuk poin persentase. Enam desimal pada n sama dengan 740 adalah presisi semu.
5. Periksa ulang pernyataan bahwa task3 gagal mencapai gate 0.70. Akurasi pembanding 0.6676 dengan selang kepercayaan [0.6328, 0.7006] sebenarnya menyentuh 0.70, sehingga pernyataan gagal pun tidak kokoh secara statistik. Ini satu alasan lagi untuk membuang gate tersebut sama sekali, sesuai butir R35.

Bukti yang diserahkan. Seluruh tabel hasil dengan kolom selang kepercayaan, dan tabel uji McNemar untuk setiap pasangan model yang dibandingkan.

R26. Koreksi Bias Seleksi dari Puluhan Konfigurasi pada Korpus yang Sama

Prioritas: P2 **Tenggat:** 16 November 2026

Temuan. Lampiran notebook 03 memuat sekitar 40 konfigurasi eksperimen, seluruhnya dievaluasi pada 740 sampel yang sama dengan pembagian fold yang sama.

Mengapa ini penting. Nilai pemenang adalah maksimum dari puluhan kali pengambilan pada korpus yang sama, sehingga bias optimistis secara sistematis. Mekanismenya sederhana. Setiap konfigurasi menghasilkan skor yang mengandung komponen acak akibat ukuran sampel terbatas, dan memilih yang tertinggi berarti memilih konfigurasi yang kebetulan mendapat komponen acak paling menguntungkan. Pada n sama dengan 740 dengan 40 percobaan, besaran bias ini bisa mencapai beberapa poin persentase. Kamu sudah menulis keterbatasan ini dalam notebook, dan itu bagus, tetapi kesadaran saja tidak memperbaiki angkanya.

Tindakan yang harus dilakukan. Pilih salah satu dari tiga jalan, dan nyatakan pilihannya di bagian metode.

1. Jalan pertama, paling kuat. Sisihkan satu fold penuh berisi 148 sampul sebagai holdout final yang tidak pernah dipakai untuk seleksi apa pun, lalu laporkan angka utama hanya dari holdout itu. Konsekuensinya seluruh seleksi harus diulang pada 592 sampul sisanya, dan angka akhirnya akan lebih rendah tetapi sahih. Jalan ini hanya mungkin kalau kamu benar-benar belum pernah melihat skor per fold saat memilih, dan karena kamu sudah melihatnya, jalan ini sebenarnya sudah tertutup.

2. Jalan kedua, realistis untuk sisa waktu. Nyatakan terbuka bahwa angka utama adalah maksimum seleksi pada korpus yang dipakai berulang, sertakan jumlah konfigurasi yang diuji, dan tempatkan pernyataan itu di abstrak serta bagian keterbatasan, bukan disembunyikan di catatan kaki.
3. Jalan ketiga, pelengkap jalan kedua. Kumpulkan sampul Tempo tahun 2026 yang belum masuk korpus sebagai set validasi eksternal kecil, misalnya 60 sampul, lalu anotasi dan evaluasi model final di sana satu kali saja. Set sekecil itu tidak memberi presisi tinggi, tetapi memberi bukti bahwa modelmu tidak runtuh di luar korpus seleksi.
4. Apa pun jalan yang dipilih, sertakan jumlah pasti konfigurasi yang pernah dievaluasi. Angka 40 itu sendiri adalah informasi yang dibutuhkan pembaca untuk menilai hasilmu.

Bukti yang diserahkan. Pernyataan pilihan jalan beserta alasannya, dan hasil set validasi eksternal kalau jalan ketiga dipilih.

R27. Ablasi Multi-Task Learning versus Single-Task

Prioritas: P2. Membuktikan klaim kebaruan utama proposal **Tenggat:** 16 November 2026

Temuan. Lampiran notebook 03 memuat baris bernama e48_single_task_diagnostic, tetapi angkanya tidak pernah ditampilkan di sel mana pun dan tidak muncul dalam tabel peringkat.

Mengapa ini penting. Klaim kebaruan utama proposalmu adalah arsitektur Multi-Task Learning dengan Joint Loss mengungguli tiga model single-task terpisah. Klaim itu bersifat komparatif, sehingga hanya dapat dibuktikan dengan pembanding single-task. Pembanding itu ternyata sudah pernah kamu jalankan, tetapi hasilnya tidak pernah dibuka. Ini kehilangan yang disayangkan, karena e48 adalah eksperimen paling penting dalam seluruh daftar untuk membela judul penelitianmu. Tanpa angka itu, seluruh bagian Multi-Task Learning dalam naskah hanya mengutip literatur orang lain dan tidak membuktikan apa pun tentang kasusmu sendiri.

Tindakan yang harus dilakukan.

1. Buka hasil e48_single_task_diagnostic secara lengkap, dengan macro-F1, akurasi, kappa, dan metrik per kelas pada ketiga task.
2. Pastikan e48 memakai backbone, fitur, augmentasi, dan protokol split yang identik dengan model utama. Kalau ada perbedaan selain jumlah head, eksperimen itu bukan ablasi MTL murni dan harus dijalankan ulang.
3. Sajikan perbandingan langsung MTL versus single-task per task, lengkap dengan uji McNemar dan selang kepercayaan.
4. Buka juga e49_task_routed_mtl dan J01_hierarchical_task2 sebagai varian MTL, sehingga keluarga MTL terwakili lengkap.
5. Kalau ternyata MTL tidak mengungguli single-task, laporkan apa adanya. Pada korpus 740 sampel dengan tiga task yang hanya berbagi sedikit informasi, hasil itu sangat mungkin dan tetap merupakan temuan yang sah. Butir R33 menjelaskan cara membingkainya.
6. Periksa apakah uncertainty weighting Kendall benar-benar diimplementasikan. Kalau Joint Loss ternyata hanya penjumlahan tiga loss dengan bobot tetap, judul dan metode harus dikoreksi, dan sitasi Kendall pada butir R16 Agustus menjadi tidak berlaku.

Bukti yang diserahkan. Tabel perbandingan MTL versus single-task per task, dan potongan kode fungsi Joint Loss yang sebenarnya dijalankan.

R28. Penyimpanan Ulang Prediksi Mentah Ablasi Unimodal

Prioritas: P2 **Tenggat:** 16 November 2026

Temuan. Ablasi unimodal sudah ada dan hasilnya baik, tetapi kolom precision_macro dan recall_macro untuk ketiga baris historis bernilai Not Evaluated karena prediksi mentahnya tidak disimpan.

Konfigurasi (macro-F1)	Task 1	Task 2	Task 3	Prediksi
Majority baseline	0.0356	0.0641	0.0746	tidak ada
Image-only (CLIP)	0.2633	0.3038	0.2390	tidak ada
Text-only (IndoBERT)	0.3480	0.2191	0.2150	tidak ada
Multimodal CLIP-IndoBERT	0.4380	0.3197	0.2764	ada
Keunggulan multimodal	+9.00 pp	+1.59 pp	+3.74 pp	

Mengapa ini penting. Keunggulan multimodal memang ada pada ketiga task, dan pada task1 selisihnya 9 poin persentase yang cukup meyakinkan. Tetapi pada task2 selisihnya hanya 1,59 poin persentase di atas image-only, dan tanpa prediksi mentah kamu tidak dapat menjalankan uji McNemar untuk membuktikan bahwa selisih sekecil itu bukan derau. Klaim multimodal pada task2 karena itu tidak dapat dipertahankan dalam bentuknya sekarang. Padahal justru task2 adalah task dekoding metafora yang menjadi inti judul penelitian.

Tindakan yang harus dilakukan.

1. Jalankan ulang ketiga ablasi unimodal dengan protokol, split, dan seed yang identik dengan model utama, lalu simpan prediksi mentah per sampel dalam format yang sama dengan predictions.csv.
2. Jalankan uji McNemar untuk multimodal melawan image-only dan multimodal melawan text-only, per task.
3. Laporkan macro-precision, macro-recall, kappa, dan metrik per kelas untuk ketiganya, bukan hanya macro-F1.
4. Tambahkan satu konfigurasi yang belum ada, yaitu text-only memakai judul ditambah supporting_text_verified. Konfigurasi ini penting karena pembanding Qwen menerima supporting text sementara model utama tidak, sesuai butir R21.
5. Mulai sekarang, simpan prediksi mentah untuk setiap eksperimen tanpa kecuali. Berkas prediksi 740 baris berukuran sangat kecil, sementara kehilangannya membuat eksperimen tidak dapat diuji secara statistik selamanya.

Bukti yang diserahkan. Empat berkas predictions.csv untuk ablasi unimodal, dan tabel uji McNemar multimodal versus unimodal.

R29. Ablasi Backbone Visual, dan Masalah bahwa Data Sendiri Menunjuk SigLIP2

Prioritas: P2 **Tenggat:** 23 November 2026

Temuan. Keluarga M01 sampai M04 adalah ablasi backbone. Menurut macro-F1 minimum, urutannya tidak menguntungkan CLIP.

Konfigurasi	Min micro-F1	Min macro-F1	Peringkat macro
M04_siglip2_adapters	0.4622	0.3805	#5 dari 36
M02_siglip2_indobert	0.4541	0.3749	#7 dari 36
M01_clip_indobert	0.3878	0.3581	#14 dari 36
M03_dinov2_indobert	0.4284	0.2859	#29 dari 36

Mengapa ini penting. Kamu akan melaporkan CLIP sebagai cabang visual arsitektur yang diusulkan, sementara datamu sendiri menunjukkan SigLIP2 unggul 2,24 poin persentase macro-F1 di atas CLIP pada pasangan M02 melawan M01, dan unggul 2,24 poin persentase lagi dengan adapter pada M04. Penguji yang membaca lampiranmu akan menemukan ini dan bertanya mengapa arsitektur yang diusulkan memakai backbone yang menurut eksperimenmu sendiri bukan yang terbaik. Pertanyaan itu harus dijawab lebih dahulu di dalam naskah, bukan di ruang sidang.

Tindakan yang harus dilakukan.

1. Buka macro-F1 per task untuk M01 sampai M04, bukan hanya nilai minimumnya.
2. Jalankan uji McNemar M02 melawan M01 untuk memastikan selisih 2,24 poin persentase itu nyata. Pada n sama dengan 740, selisih sebesar itu kemungkinan besar belum signifikan, dan kalau memang begitu jawabanmu menjadi mudah, yaitu kedua backbone setara secara statistik.
3. Kalau selisihnya ternyata signifikan, siapkan jawaban yang jujur. Pilihan pertama, pertahankan CLIP karena proposal yang didanai menetapkannya, lalu laporkan SigLIP2 sebagai arah pengembangan lanjutan. Pilihan kedua, laporkan SigLIP2 sebagai temuan dan koreksi judul. Pilihan pertama lebih aman untuk sisa waktu dan tetap jujur.
4. Pastikan keempat konfigurasi memakai head, augmentasi, dan split identik, sehingga perbandingannya memang ablasi backbone murni dan bukan gabungan beberapa perubahan sekaligus.
5. Catat varian CLIP yang dipakai secara tepat. Nama e36_clip_l14 menunjukkan ada varian ViT-L/14, sementara M01 mungkin memakai varian lain. Perbedaan ini penting dan sekaligus menentukan kelayakan GRAD-CAM pada butir R34.

Bukti yang diserahkan. Tabel ablasi backbone per task dengan uji McNemar, dan pernyataan varian CLIP yang dipakai model utama.

R30. Ablasi Augmentasi dan Keganjilan AUG_SELECTED

Prioritas: P2 **Tenggat:** 23 November 2026

Temuan. Keluarga A00 sampai A03 adalah ablasi augmentasi, dan konfigurasi yang akhirnya dipakai bukan yang terbaik.

Konfigurasi	Min micro-F1	Min macro-F1	Catatan
A01_light	0.4649	0.3663	terbaik pada kedua metrik
A00_none (tanpa augmentasi)	0.4608	0.3595	nyaris setara A01
A03_light_sampler	0.4541	0.3556	
AUG_SELECTED / selected_pipeline_oof	0.4514	0.3564	konfigurasi yang dipakai
A02_moderate	0.4595	0.3307	augmentasi lebih berat, hasil lebih buruk

Mengapa ini penting. Ada dua hal. Pertama, AUG_SELECTED lebih rendah daripada A01_light pada kedua metrik sekaligus, yaitu 1,35 poin persentase pada micro dan 0,99 poin persentase pada macro. Konfigurasi yang dipilih bukan konfigurasi terbaik menurut eksperimennya sendiri, dan tidak ada penjelasan mengapa. Kedua, pola A00 sampai A02 menunjukkan augmentasi ringan nyaris tidak membantu sementara augmentasi sedang justru merusak, dengan penurunan 2,88 poin persentase macro dari A00 ke A02. Pola ini konsisten dengan peringatan pada butir R10 Agustus, bahwa augmentasi geometris menghancurkan komposisi visual yang justru menjadi objek semiotikanya.

Tindakan yang harus dilakukan.

1. Jelaskan secara tertulis mengapa AUG_SELECTED dipilih padahal A01_light lebih baik. Kalau alasannya kebutuhan pipeline lain, nyatakan. Kalau tidak ada alasan, ganti ke A01_light.
2. Dokumentasikan isi persis setiap tingkat augmentasi. Transformasi apa saja, dengan parameter berapa, pada A00, A01, A02, dan A03.
3. Pastikan rotasi dan cropping sudah dihapus sesuai butir R10 Agustus. Kalau masih ada, hapus, lalu jalankan ulang.
4. Laporkan temuan bahwa augmentasi memberi manfaat kecil atau justru merugikan sebagai hasil penelitian. Pada data semiotika yang tata letaknya bermakna, temuan ini masuk akal secara teoretis dan menarik untuk dibahas. Kaitkan dengan kerangka semiotika pada bab tinjauan pustaka.
5. Periksa keluaran back-translation pada modalitas teks secara manual, minimal 30 contoh, sesuai butir R10 Agustus. Judul sampul Tempo sarat permainan kata yang hancur setelah diterjemahkan bolak-balik.

Bukti yang diserahkan. Dokumentasi parameter augmentasi, penjelasan pemilihan AUG_SELECTED, dan catatan pemeriksaan 30 contoh back-translation.

R31. Kelas Penampung dan Pemecahan Task 2

Prioritas: P2 **Tenggat:** 23 November 2026

Temuan. Pada tabel per kelas, kelas penampung adalah kelas terburuk pada ketiga task tanpa kecuali.

Kelas penampung	Task	Presisi	Recall	F1	Support
other_issue	task1	0.571	0.286	0.381	14

Kelas penampung	Task	Presisi	Recall	F1	Support
LAINNYA	task2	0.412	0.111	0.175	63
multiple_or_other	task3	0.500	0.279	0.358	122

Macro-F1 tanpa kelas penampung naik menjadi 0.706 pada task1, 0.566 pada task2, dan 0.629 pada task3, masing-masing naik 3,25 sampai 5,59 poin persentase. Kelas multiple_or_other sendiri memegang 16,5 persen seluruh data task3.

Mengapa ini penting. Kelas penampung secara semantik tidak koheren, karena isinya hanya "segala sesuatu yang tidak masuk kategori lain". Model tidak mungkin mempelajari konsep yang tidak punya ciri bersama. Recall 0.111 pada LAINNYA berarti hanya 7 dari 63 sampul tertebak benar. Ini persis masalah definisi codebook yang menjadi butir R2 Agustus, dan sekarang dampaknya terukur dalam angka.

Task2 juga mencampur dua masalah berbeda dalam satu head. Kelas NON_METAFORA berisi 83 sampul dengan recall hanya 0.482, artinya lebih separuh sampul tanpa metafora justru diberi label domain metafora. Kalau dipisah, akurasi pada 657 sampul bermetafora adalah 0.577. Deteksi keberadaan metafora dan klasifikasi domain sumber adalah dua pertanyaan penelitian yang berbeda dan menuntut pelaporan terpisah.

Tindakan yang harus dilakukan.

1. Laporkan macro-F1 dalam dua versi, yaitu dengan dan tanpa kelas penampung, lalu jelaskan selisihnya. Jangan memilih salah satu secara diam-diam.
2. Periksa 30 sampul yang berlabel multiple_or_other dan 30 yang berlabel LAINNYA. Kalau ternyata ada subkelompok yang koheren di dalamnya, pecah menjadi kelas baru. Kalau isinya memang beragam, nyatakan terbuka bahwa kelas ini tidak dapat dipelajari dan jelaskan alasannya.
3. Pecah pelaporan task2 menjadi dua angka. Pertama, deteksi biner keberadaan metafora dengan presisi, recall, dan F1-nya. Kedua, klasifikasi domain sumber pada 657 sampul bermetafora saja.
4. Pertimbangkan melatih task2 sebagai dua head terpisah, yaitu deteksi dan klasifikasi domain. Kalau waktu tidak cukup, cukup pisahkan pada tahap pelaporan dan nyatakan sebagai saran pengembangan.
5. Hubungkan temuan ini ke bab metode sebagai pelajaran tentang perancangan skema label. Bagian ini akan menjadi sumbangan praktis naskahmu bagi peneliti berikutnya.

Bukti yang diserahkan. Tabel macro-F1 dua versi, catatan pemeriksaan 60 sampul kelas penampung, dan tabel task2 terpisah.

R32. Paket Reproduksi yang Tidak Self-Contained

Prioritas: P2 **Tenggat:** 23 November 2026

Temuan. Arsip yang kamu kirim hanya berisi tiga berkas .ipynb. Sel pertama setiap notebook mencari tools/analysis.py dan project/DEMO_XAI_745_FULL, dan kalau tidak ditemukan akan melempar FileNotFoundError. Tidak satu pun berkas itu disertakan.

Mengapa ini penting. Notebook yang tidak dapat dijalankan kehilangan sebagian besar nilainya sebagai bukti. Seluruh disiplin hashing dan verifikasi yang kamu bangun dengan susah payah tidak dapat

diverifikasi pihak lain. Saya terpaksa bersandar pada keluaran tersimpan, dan penguji akan menghadapi kendala yang sama. Untuk naskah jurnal, kemampuan reproduksi semakin sering diminta secara eksplisit.

Tindakan yang harus dilakukan.

1. Susun satu arsip reproduksi yang benar-benar lengkap, berisi notebook, tools/analysis.py, seluruh berkas result.json dan predictions.csv, berkas split, dan dataset berlabel.
2. Sertakan berkas REQUIREMENTS dengan versi persis setiap pustaka, dan berkas README berisi langkah menjalankan dari nol.
3. Ubah penanganan ROOT supaya memberi pesan yang jelas, bukan FileNotFoundError mentah. Sertakan juga mode yang membaca keluaran tersimpan tanpa memerlukan berkas berat.
4. Uji arsip itu pada lingkungan bersih, misalnya Colab baru tanpa Drive, dan pastikan seluruh sel berjalan dari atas ke bawah tanpa intervensi.
5. Kalau citra sampul tidak boleh disertakan karena alasan hak cipta sesuai butir R3 Agustus, sertakan fitur terekstraksi dan prediksi saja, lalu nyatakan pembatasannya di README.

Bukti yang diserahkan. Satu arsip reproduksi yang sudah diuji pada Colab bersih, beserta tangkapan layar hasil Run all.

Bagian C. Revisi Prioritas P3 (Perumusan di Manuskrip)

R33. Pembingkaian Naskah sebagai Hasil Negatif Terkendali

Prioritas: P3 **Tenggat:** 24 Desember 2026

Temuan. Dengan CLIP-IndoBERT sebagai model utama, angka yang akan dilaporkan adalah sebagai berikut.

Task	Akurasi	CI 95%	Macro-F1	Majority	Status
task1_issue	0.4554	[0.420, 0.491]	0.4380	0.2162	di atas majority
task2_domain_sumber	0.3203	[0.288, 0.355]	0.3197	0.2892	tipis di atas
task3_primary_entity_type	0.3554	[0.322, 0.391]	0.2764	0.4257	DI BAWAH majority

Mengapa ini penting. Arsitektur yang diusulkan hanya unggul meyakinkan pada task1. Pada task2 keunggulannya 3,11 poin persentase atau 23 sampul, dan uji McNemar memberi p antara 0,03 dan 0,20 tergantung tingkat diskordansi, sehingga belum dapat diandalkan. Pada task3 arsitektur ini kalah 7,03 poin persentase dari majority baseline, dan kekalahan itu signifikan. Naskah yang mencoba menyajikan ini sebagai keberhasilan akan runtuh pada pertanyaan pertama penguji. Naskah yang menyajikannya sebagai hasil negatif terkendali justru kuat, karena kamu punya ablasi lengkap, protokol beku, hashing, dan pembanding VLM yang jarang dimiliki penelitian tingkat sarjana.

Tindakan yang harus dilakukan. Susun ulang alur argumen naskah mengikuti enam langkah berikut.

1. Nyatakan sejak abstrak bahwa penelitian ini menguji kelayakan arsitektur MTL CLIP-IndoBERT untuk dekoding metafora multimodal pada sampul pers Indonesia, dan menemukan keterbatasan yang jelas beserta sebab-sebabnya. Jangan menjanjikan keberhasilan di abstrak lalu melaporkan kegagalan di bagian hasil.
2. Sajikan tiga sumbangan utama secara eksplisit. Pertama, dataset semiotika teranotasi 740 sampul yang belum pernah ada. Kedua, temuan bahwa pemilihan metrik menentukan arah seleksi arsitektur pada data timpang, dengan bukti pembalikan peringkat 31 posisi. Ketiga, pemetaan batas kemampuan arsitektur fitur beku pada tugas ini, dengan pembanding VLM sebagai batas atas.
3. Tempatkan Qwen3-VL sebagai pembanding batas atas, bukan sebagai pesaing. Rumusannya kira-kira begini. Model visual-bahasa berskala besar mencapai macro-F1 0.673/0.510/0.595 pada tugas yang sama, sehingga tugas ini memang dapat dipelajari, dan keterbatasan arsitektur fitur beku bukan karena tugasnya mustahil.
4. Laporkan bahwa task3 kalah dari majority baseline secara terbuka di bagian hasil, bukan di catatan kaki. Lalu jelaskan sebabnya memakai analisis kolaps kelas mayoritas pada butir R20. Penjelasan yang tepat atas kegagalan jauh lebih bernilai daripada menyembunyikannya.
5. Bandingkan kappa model dengan kappa antaranotator dari butir R23. Kalau ternyata kappa manusia juga rendah pada task2, naskahmu berubah menjadi temuan langit-langit anotasi, dan temuan semacam itu justru layak terbit.

6. Tutup dengan arah pengembangan yang didasarkan pada bukti dari penelitian ini sendiri, bukan pada spekulasi. Misalnya fine-tuning backbone visual, penggantian ke SigLIP2 menurut butir R29, pemecahan task2 menurut butir R31, dan perbaikan skema label kelas penampung.

R34. Modul Explainable AI yang Kembali Menjadi Wajib

Prioritas: P3. Setengah dari judul penelitian **Tenggat:** 7 Desember 2026

Temuan. Saya cari kata grad-cam, gradcam, lime, faithfulness, interpretability, rubrik, Likert, dan penilai di ketiga notebook. Nol kemunculan. Kata XAI hanya muncul sebagai bagian nama folder DEMO_XAI_745_FULL sebanyak 73 kali dan nama berkas xai_core.py sebanyak 2 kali.

Mengapa ini penting. Modul eksplanasi adalah setengah dari judul penelitian dan satu dari tiga target inti yang dijanjikan proposal. Saat ini modul itu tidak ada dalam pekerjaan yang diserahkan. Ada satu kabar baik dari keputusanmu mempertahankan CLIP-IndoBERT sebagai model utama. Rancangan XAI proposal menjadi layak kembali, karena GRAD-CAM dan LIME memang dirancang untuk arsitektur semacam itu. Seandainya Qwen3-VL yang dilaporkan sebagai model utama, seluruh rancangan XAI proposal akan mati, karena model generatif yang mengeluarkan satu token huruf tidak punya peta fitur konvolusional dan tidak punya cabang teks terpisah untuk diperturbasi. Kabar baik kedua, demo web sudah menjalankan CLIP-IndoBERT, sehingga artefak demo kini konsisten dengan model yang dilaporkan. Peringatan dalam notebookmu sendiri, yaitu "jangan menganggap web sudah menggunakan E14", justru menjadi tidak relevan dan itu menguntungkan.

Tindakan yang harus dilakukan.

1. Jawab lebih dahulu butir R4 Agustus yang belum tuntas. Tentukan varian CLIP yang dipakai model utama. Kalau variannya berbasis Vision Transformer, GRAD-CAM standar tidak sahih, karena tidak ada lapisan konvolusi terakhir yang mempertahankan struktur spasial dan self-attention sudah mencampur informasi antarposisi. Peta panas yang dihasilkan akan terlihat meyakinkan tetapi tidak mencerminkan dasar keputusan model.
2. Pilih salah satu jalan. Jalan pertama, pakai varian CLIP berbasis ResNet untuk model utama sehingga GRAD-CAM sahih tanpa metode tambahan. Jalan kedua, tetap pakai Vision Transformer tetapi ganti metode eksplanasi ke pendekatan khusus transformer, yaitu Chefer, Gur, dan Wolf (ICCV 2021) untuk model bi-modal, atau attention rollout dari Abnar dan Zuidema (ACL 2020). Kalau jalan kedua dipilih, nama modul dalam naskah berubah dan tidak boleh lagi disebut GRAD-CAM.
3. Implementasikan LIME pada cabang tekstual dengan modalitas visual ditahan tetap, lalu nyatakan di bagian metode bahwa atribusinya bersifat kondisional terhadap citra tertentu, sesuai butir R15 Agustus.
4. Susun instrumen rubrik tertulis sebelum penilaian, memuat definisi operasional Faithfulness dan Interpretability dalam bahasa yang dapat dipahami penilai non-teknis.
5. Rekrut minimal lima penilai independen yang tidak terlibat anotasi, sesuai butir R9 Agustus. Saya akan membantu membuka jalur ke jaringan dosen Ilmu Komunikasi. Mulai rekrutmen awal November supaya penilai siap awal Desember.

6. Sisipkan beberapa peta panas acak sebagai kontrol tanpa memberi tahu penilai. Kalau penilai memberi skor tinggi pada kontrol acak, instrumenmu tidak mengukur apa pun. Kontrol semacam ini sangat menguatkan bagian evaluasi.
7. Laporkan kesepakatan antarpenilai memakai Krippendorff Alpha atau Intraclass Correlation Coefficient, bukan hanya rata-rata skor.
8. Kalau sampai 7 Desember modul ini tidak dapat diselesaikan, ajukan amendemen lingkup resmi dan keluarkan XAI dari judul penelitian. Keputusan itu harus diambil bersama saya dan tidak boleh dibiarkan menggantung sampai Desember akhir.

R35. Penghapusan Gate 0.70 dan Perumusan Ulang Target

Prioritas: P3 **Tenggat:** 24 Desember 2026

Temuan. Gate all_tasks_at_least_0_70 masih dipakai sebagai kriteria keberhasilan. Dasar angka 0.70 tidak pernah diperbarui sejak butir R13 Agustus menyatakan justifikasi YesBut tidak berlaku.

Mengapa ini penting. Ada tiga alasan kumulatif. Pertama, angka itu dijustifikasi dengan dataset satire berbahasa Inggris yang ruang label, jumlah kelas, dan definisi tugasnya berbeda, sehingga tidak sebanding. Kedua, gate dihitung pada micro yang identik dengan akurasi, sehingga ambang 0.70 berarti hal yang sangat berbeda antartask dengan distribusi kelas berbeda. Pada task3 dengan kelas mayoritas 42,6 persen, akurasi 0.70 jauh lebih mudah dicapai daripada pada task1 dengan kelas mayoritas 21,6 persen. Ketiga, selang kepercayaan selebar plus minus 3,3 poin persentase membuat pernyataan lulus atau gagal di sekitar 0.70 tidak stabil.

Tindakan yang harus dilakukan.

1. Hapus gate 0.70 dari kode, dari tabel, dan dari naskah. Ganti nama variabel all_tasks_at_least_0_70 atau hilangkan sama sekali.
2. Ganti dengan tiga patokan yang dapat dipertanggungjawabkan. Pertama, selisih bermakna terhadap majority baseline pada datasetmu sendiri. Kedua, selisih bermakna terhadap ablasi unimodal dan single-task. Ketiga, kedudukan kappa model relatif terhadap kappa antaranotator.
3. Rumuskan keberhasilan sebagai pernyataan komparatif, bukan sebagai pencapaian angka absolut. Rumusan komparatif lebih kuat secara ilmiah dan jauh lebih aman menghadapi reviewer.
4. Kalau indikator capaian pada dokumen proposal berskema pendanaan sudah terlanjur menyebut angka 0.75 atau 0.70, laporkan ketidaktercapaiannya secara terbuka dalam laporan akhir, beserta analisis sebabnya dan bukti bahwa prosedurnya dijalankan dengan benar. Laporan yang jujur tentang target yang tidak tercapai jauh lebih dapat dipertahankan daripada angka yang dipoles.

R36. Keterbatasan, Etika, dan Sitasi

Prioritas: P3 **Tenggat:** 24 Desember 2026

Temuan. Butir R16 dan R17 Agustus belum terlihat dikerjakan, dan pemeriksaan notebook menambah beberapa keterbatasan baru yang wajib dicantumkan.

Tindakan yang harus dilakukan.

Keterbatasan yang wajib dicantumkan

1. Korpus dipakai berulang untuk sekitar 40 konfigurasi, sehingga angka akhir adalah maksimum seleksi dan bias optimistis.
2. Seluruh data berasal dari satu penerbit dengan sudut pandang editorial tertentu, sehingga model mewarisi kerangka kritik penerbit tersebut dan tidak mewakili pers Indonesia secara umum.
3. Label metafora dan entitas sasaran adalah hasil interpretasi manusia terlatih, bukan kebenaran objektif tunggal.
4. Korpus menyusut dari 1.040 menjadi 740, beserta kriteria penyusutannya.
5. Citra pada pembanding diperkecil menjadi 384x384 piksel, sehingga teks halus pada sampul kemungkinan hilang.
6. Urutan opsi jawaban pada pembanding selalu tersortir sama untuk setiap sampel, sehingga bias posisi model tidak terkendali. Kalau sempat, jalankan ulang dengan urutan opsi diacak dan laporkan selisihnya.
7. Stratifikasi fold hanya pada task1, sehingga distribusi task2 dan task3 bergeser antarfold.
8. Fold 1 pembanding memakai ulang riwayat inner dari pilot E13, dan batas tiga epoch ditetapkan setelah melihat riwayat enam epoch. Outer test memang tidak tersentuh, tetapi keterbatasan ini tetap harus dicatat.

Etika dan potensi penyalahgunaan

1. Tambahkan dua sampai tiga paragraf tentang pembatasan penggunaan. Sistem ini memetakan lembaga mana yang menjadi sasaran kritik pers, dan kemampuan yang sama dapat dialihfungsikan untuk memantau serta menekan kritik pers.
2. Nyatakan bahwa keluaran model bersifat analitis dan deskriptif, bukan penilaian atas kebenaran atau kelayakan kritik yang dianalisis.
3. Nyatakan pembatasan distribusi model terlatih dan dataset, misalnya akses hanya untuk keperluan penelitian dengan permintaan tertulis.

Sitasi yang masih kurang

1. Kendall, Gal, dan Cipolla, "Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics", CVPR 2018, kalau uncertainty weighting memang dipakai sesuai butir R27.
2. Rujukan untuk Qwen3-VL dan untuk QLoRA, yaitu Dettmers dan kawan-kawan, pada bagian pembanding.
3. Chefer, Gur, dan Wolf (ICCV 2021) serta Abnar dan Zuidema (ACL 2020), kalau jalur eksplanasi transformer dipilih pada butir R34.
4. Rujukan metodologis untuk uji McNemar pada perbandingan pengklasifikasi, misalnya Dietterich (1998).
5. Verifikasi sendiri DOI, nomor halaman, dan tahun setiap rujukan langsung dari sumber resminya. Rujukan di atas saya tuliskan dari ingatan tanpa penelusuran daring, jadi jangan salin apa adanya.

Bagian D. Jadwal Kerja dan Gerbang Keputusan

Sisa waktu sekitar sembilan pekan. Jadwal berikut menempatkan seluruh pekerjaan komputasi selesai pada 7 Desember, menyisakan tiga pekan penuh untuk penulisan. Menulis naskah sambil masih menjalankan eksperimen adalah cara tercepat kehilangan kendali atas keduanya.

Periode	Fokus pekerjaan	Butir	Keluaran yang diperiksa
27 Okt - 2 Nov	Pemetaan kandidat, provenance fitur, mulai anotasi ganda	R18, R22, R23	Tabel pemetaan 36 baris, skrip pembangkit, jadwal anotasi ganda
3 Nov - 9 Nov	Peringkat ulang macro, diagnosis kolaps task3, kesetaraan masukan	R19, R20, R21	Tabel peringkat ganda, confusion matrix, tabel 2x2 arsitektur versus masukan
10 Nov - 16 Nov	Penggantian metrik, selang kepercayaan, ablasi MTL dan unimodal	R24, R25, R26, R27, R28	Tabel macro lengkap, tabel McNemar, hasil e48
17 Nov - 23 Nov	Ablasi backbone dan augmentasi, kelas penampung, paket reproduksi	R29, R30, R31, R32	Tabel ablasi, tabel macro dua versi, arsip reproduksi teruji
24 Nov - 7 Des	Modul XAI, rubrik, penilaian oleh penilai independen	R34	Peta panas, skor atribusi, tabel rubrik dan kesepakatan antarpenilai
8 Des - 24 Des	Penulisan manuskrip mengikuti templat jurnal sasaran	R33, R35, R36	Draf lengkap siap unggah
25 Des - 31 Des	Submit dan penyusunan laporan akhir		Bukti submit dan laporan akhir

Gerbang keputusan

Gerbang 1, 9 November 2026. Syarat lulus: model utama sudah ditetapkan dan dibekukan, peringkat ulang macro atas 36 kandidat selesai, provenance deskripsi.jsonl dan zeroshot.jsonl terbukti bersih, dan anotasi ganda untuk kappa sudah berjalan. Kalau provenance ternyata tercemar, seluruh hasil task2 dibatalkan dan lingkup dipangkas menjadi dua task. Kalau model utama belum beku, penulisan ditunda dan seluruh jadwal berikutnya mundur.

Gerbang 2, 23 November 2026. Syarat lulus: seluruh ablasi selesai dengan macro-F1, kappa, selang kepercayaan, dan uji McNemar, serta arsip reproduksi sudah diuji pada lingkungan bersih. Kalau gagal, ablasi backbone dan augmentasi dipangkas, lalu naskah membatasi klaim hanya pada ablasi unimodal dan MTL yang sudah selesai.

Gerbang 3, 7 Desember 2026. Syarat lulus: modul XAI menghasilkan peta panas dan skor atribusi yang sahih, dan penilaian rubrik oleh minimal lima penilai independen selesai. Kalau gagal, ajukan amendemen lingkup resmi, keluarkan XAI dari judul, lalu pindahkan ke bagian pengembangan lanjutan. Keputusan ini diambil bersama saya pada tanggal tersebut dan tidak boleh digantung.

Artefak wajib per pertemuan

Pertemuan mingguan sampai akhir Desember, naik dari dua mingguan karena sisa waktu menipis. Setiap pertemuan kamu wajib membawa satu artefak yang dapat diperiksa, bukan laporan lisan.

1. Tabel pemetaan 36 kandidat beserta spesifikasi arsitekturnya
2. Bukti provenance kedua berkas fitur tambahan

3. Tabel peringkat ganda micro versus macro
4. Confusion matrix dan analisis kolaps kelas mayoritas task3
5. Tabel 2x2 arsitektur versus kekayaan masukan
6. Tabel kappa antaranotator berdampingan dengan kappa model
7. Tabel ablasi lengkap dengan selang kepercayaan dan uji McNemar
8. Arsip reproduksi yang sudah diuji pada Colab bersih
9. Instrumen rubrik dan hasil penilaian XAI
10. Draf manuskrip mengikuti templat jurnal sasaran

Bagian E. Lembar Lacak Status Revisi

Isi kolom Status pada setiap pertemuan dengan salah satu dari: Belum, Berjalan, Selesai, atau Dibantah. Kalau kamu mengisi Dibantah, siapkan alasan teknisnya untuk dibahas.

No	Butir revisi	Prio	Tenggat	Status
R18	Tetapkan dan bekukan identitas model utama	P1	31 Okt 2026	
R19	Peringkat ulang seluruh kandidat memakai macro-F1	P1	3 Nov 2026	
R20	Diagnosis kolaps kelas mayoritas pada task3	P1	3 Nov 2026	
R21	Kesetaraan masukan model utama dan pembanding	P1	9 Nov 2026	
R22	Provenance deskripsi.jsonl dan zeroshot.jsonl	P1	31 Okt 2026	
R23	Kappa antaranotator dan riwayat 1.040 ke 740	P1	9 Nov 2026	
R24	Penggantian metrik utama ke macro-F1 dan kappa	P2	10 Nov 2026	
R25	Selang kepercayaan dan uji McNemar	P2	16 Nov 2026	
R26	Koreksi bias seleksi puluhan konfigurasi	P2	16 Nov 2026	
R27	Ablasi MTL versus single-task (e48)	P2	16 Nov 2026	
R28	Penyimpanan ulang prediksi ablasi unimodal	P2	16 Nov 2026	
R29	Ablasi backbone dan persoalan SigLIP2	P2	23 Nov 2026	
R30	Ablasi augmentasi dan keganjilan AUG_SELECTED	P2	23 Nov 2026	
R31	Kelas penampung dan pemecahan task2	P2	23 Nov 2026	
R32	Paket reproduksi yang self-contained	P2	23 Nov 2026	
R33	Pembingkaian naskah sebagai hasil negatif terkendali	P3	24 Des 2026	
R34	Modul Explainable AI dan penilai independen	P3	7 Des 2026	
R35	Penghapusan gate 0.70 dan perumusan ulang target	P3	24 Des 2026	
R36	Keterbatasan, etika, dan sitasi	P3	24 Des 2026	

Catatan Penutup

Sembilan belas butir baru dalam satu dokumen terlihat berat, dan saya tidak akan berpura-pura sebaliknya. Perlu kamu tahu bahwa sebagian besarnya berasal dari satu akar yang sama, yaitu pemilihan Micro-F1 sebagai metrik utama. Butir R19, R20, R24, R25, R29, R30, dan sebagian R33 semuanya turunan dari akar itu. Memperbaiki satu keputusan metrik akan menuntaskan separuh daftar ini sekaligus.

Perlu juga dicatat bahwa pekerjaanmu tidak sia-sia. Seluruh prediksi tersimpan, protokol terdokumentasi, dan hash terverifikasi, sehingga hampir semua butir di atas dapat diselesaikan dengan menghitung ulang metrik dari berkas yang sudah ada. Sangat sedikit yang memerlukan pelatihan ulang.

Justru karena kamu menyimpan segalanya dengan rapi, koreksi sebesar ini masih mungkin dikerjakan dalam sembilan pekan. Peneliti yang tidak menyimpan prediksi mentahnya tidak akan punya pilihan itu.

Satu hal tentang hasil yang tidak sesuai harapan. Arsitektur yang diusulkan ternyata kalah dari majority baseline pada satu task, dan hanya unggul tipis pada task lainnya. Itu bukan aib. Penelitian yang memetakan batas sebuah pendekatan dengan ablasi lengkap, protokol beku, dan pembanding yang jujur bernilai lebih tinggi daripada penelitian yang melaporkan angka tinggi tanpa bisa menjelaskan dari mana angkanya datang. Pembalikan peringkat 31 posisi yang kamu temukan tanpa sengaja itu temuan nyata, dan kalau ditulis dengan baik, bisa jadi bagian naskah yang paling banyak dikutip.

Kalau ada butir yang menurutmu keliru, saya ingin mendengar bantahannya lengkap dengan alasan teknis. Beberapa butir di atas saya susun dari keluaran notebook tanpa akses ke berkas pendukung, jadi sangat mungkin ada yang sudah kamu kerjakan tetapi tidak terlihat dari sana. Bawa bantahanmu ke pertemuan berikutnya.